TP

September 24, 2017

TP Datos - Análisis exploratorio de datos

El presente trabajo es un análisis exploratorio de datos basado en las publicaciones de venta de propiedades, publicadas en un lapso de 4 años, proporcionadas por la empresa Properati

In [2]:
```
%matplotlib inline

import matplotlib
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import matplotlib.pylab as pylab
from os import listdir
from os.path import isfile, join
import calendar
import geopandas as gpd
from shapely.geometry import Point
from shapely.geometry import Polygon
from scipy import ndimage
import shapely


plt.style.use('default') # haciendo los graficos un poco mas bonitos xD
plt.rcParams['figure.figsize'] = (5, 5)
```

1 Filtrado de datos de los archivos CSV de cada mes

Aquí declaramos algunas funciones útiles que usaremos para poder realizar un chequeo de consistencia sobre el cálculo de los precios de las propiedades en venta.

In [4]:
```
# Filtro de propiedades con precio calculable. Devuelve 1 si es válido.
# De lo contrario, nan (Not A Number)
def filter(array):
    priceUSD, usdM2, surfaceTotal = array
    if np.isnan(surfaceTotal) or surfaceTotal == 0:
        return np.nan
    if not np.isnan(priceUSD) and not np.isnan(usdM2):
        price = usdM2 * surfaceTotal
```

```
            dif = abs(price - priceUSD)
            if ((dif / priceUSD) * 100) <= 10:
                return 1
        return 1

    # Cálculo del precio aproximado de venta
    def fillPrice(array):
        priceUSD, usdM2, surfaceTotal = array
        if np.isnan(priceUSD) and not np.isnan(usdM2):
            return (usdM2 * surfaceTotal)
        return priceUSD

    # Cálculo del precio del metro cuadrado
    def fillM2(array):
        priceUSD, usdM2, surfaceTotal = array
        if not np.isnan(priceUSD) and np.isnan(usdM2):
            return (priceUSD / surfaceTotal)
        return usdM2
```

2 Hacemos un rápido chequeo de los archivos para saber si alguno se descargó mal

In [ ]:
```
"""
# Ruta de la carpeta con los archivos de datos originales
rutaCarpetaOriginales = "./properties/"
for archive in listdir(rutaCarpetaOriginales):
    if ".csv" in archive:
        nombreArchivo = rutaCarpetaOriginales + archive
        try:
            print nombreArchivo
            df = pd.read_csv(nombreArchivo, low_memory = False)
            print('Ok')
        except ValueError:
            print("Error, archivo corrupto. Descargar de nuevo")"""
```

3 Filtrado y concatenacion de todos los archivos CSV en un solo archivo

En esta parte del código se filtraron columnas de los archivos csv que no ibamos a a usar. Tambiénse filtraron propiedades que no pertenezcan a Capital Federal o Gran Buenos Aires, ya que solo vamos a acotar nuestro análisis a estos dos lugares. Tambien fué necesario renombrar la columna de superficie ya que algunos archivos CSV tenian nombres distintos y es necesario que todos refieran al mismo. Luego agregamos la columna llamada Date la cual refiere a la fecha en la cualfue publicada cada propiedad. Se uso esta fecha ya que la columna 'created_on' no refleja laevolucion del precio de las propiedades en funcion del tiempo y distorciona el analisis de

datos. En cambio la fecha de publicacion muestra la actualizacion a la fecha de los precios de cada propiedad.

Tambien se filtraron porpiedades en función de la validez de sus datos. Es decir, que si el valor en dolares por metro cuadradro multiplicado por la superficie no se encontraba en un rango menor al 10% respecto del precio en dolares, se descartaban. Finalmente concatenamos todos los archivos abiertos los cuales fueron almacenados en un vector de DataFrames. Se tiene que tener en cuenta que al realizar la concatenación se crearon cien columnas vacias con nombre "unnmaed: 0" a "unnmaed: 99" por lo cual se tuvieron que eliminar del dataframe concatenado. Luego grabamos el DataFrame concatenado en un archivo CSV para trabajar de ahora en mas con este ultimo

```
In [ ]: """# Ruta de la carpeta con los archivos de datos modificados
        root = "./properties/"
        properties = []
        indexAcum = 0
        for archive in listdir(root):
            if ".csv" not in archive:
                continue
            df = pd.read_csv(root + archive, low_memory = False)
            df = df.loc[df.place_with_parent_names.str.contains('Capital Federal') \
                | df.place_with_parent_names.str.contains('Bs.As. G.B.A.'), :]

            # Durante la carga de datos, se eliminan ciertas columnas que nos
            #resultan irrelevantes para el trabajo como urls.
            if 'properati_url' in df:
                df.drop('properati_url', axis = 1, inplace = True)
            if 'geonames_id' in df:
                df.drop('geonames_id', axis = 1, inplace = True)
            if 'description' in df:
                df.drop('description', axis = 1, inplace = True)
            if 'image_thumbnail' in df:
                df.drop('image_thumbnail', axis = 1, inplace = True)
            if 'operation' in df:
                df.drop('operation', axis = 1, inplace = True)
            if 'created_on' in df:
                df.drop('created_on', axis = 1, inplace = True)
            if 'lat-lon' in df:
                df.drop('lat-lon', axis = 1, inplace = True)
            if 'currency' in df:
                df.drop('currency', axis = 1, inplace = True)
            if 'title' in df:
                df.drop('title', axis = 1, inplace = True)
            if 'id' in df:
                df.drop('id', axis = 1, inplace = True)
            if 'price_aprox_local_currency' in df:
                df.drop('price_aprox_local_currency', axis = 1, inplace = True)
            if 'price_aprox_usd' in df and 'price' in df:
                df.drop('price', axis = 1, inplace = True)
            if 'extra' in df and 'price' in df:
```

```
        df.drop('extra', axis = 1, inplace = True)

    # En algunos casos, es necesario renombrar algunas columnas
    if 'price_aprox_usd' not in df:
        df.rename(columns = {'price': 'price_aprox_usd'}, inplace = True)
    if 'surface_total_in_m2' not in df:
        df.rename(columns = {'surface_in_m2': 'surface_total_in_m2'}, \
            inplace = True)

    # Aquí reconvertimos algunas columnas a punto flotante
    df.loc[:, 'price_aprox_usd'] = df.loc[:, ['price_aprox_usd']]\
        .apply(lambda x: float(x), axis = 1)
    df.loc[:, 'price_usd_per_m2'] = df.loc[:, ['price_usd_per_m2']]\
        .apply(lambda x: float(x), axis = 1)

    # obtenemos el año y mes del nombre de archivo
    date_splitted = archive.split('-')
    month = date_splitted[3]
    year = date_splitted[2]
    date = year + '-' + month
    size = len(df.index)
    dates = pd.Series([date for i in range(0, size)])
    # y lo ponemos como dato en una columna
    df['date'] = dates
    df.loc[:, ['date']] = pd.to_datetime(df['date'], errors = 'coerce')

    # Aquí aplicamos el filtro antes declarado
    df['filter'] = df.loc[:, ['price_aprox_usd', 'price_usd_per_m2', \
        'surface_total_in_m2']].apply(filter, axis = 1)
    df = df[~np.isnan(df['filter'])]
    df.loc[:, ['price_aprox_usd']] = df.loc[:, ['price_aprox_usd', \
        'price_usd_per_m2', 'surface_total_in_m2']].apply(fillPrice, axis = 1)
    df.loc[:, ['price_usd_per_m2']] = df.loc[:, ['price_aprox_usd', \
        'price_usd_per_m2', 'surface_total_in_m2']].apply(fillM2, axis = 1)
    df.drop('filter', axis = 1, inplace = True)

    # Finalmente, guardamos los archivos modificados.
    size = len(df.index)
    if size != 0:
        indexAcum += size
        newIndex = [i for i in range(indexAcum, indexAcum+size)]
        df.reindex(newIndex)
        print archive
        properties.append(df)

#Genero un nuevo csvcon la concatenacion de todos ellos en uno solo
general = pd.concat(properties)
```

```
        #Borro las columnas vacias
        for column in general.columns.values:
            if 'Unnamed' not in column:
                continue
            general.drop(column, axis = 1, inplace = True)

        general.loc[:, ['date']] = pd.to_datetime(general['date'], errors = 'coerce')

        #Grabo la concatenacion en un unico csv
        try:
            general.to_csv("propertiesConCat.csv", index = True, header = True, \
                sep = ',', encoding = 'utf-8-sig')
            print('Done')
        except value:
            print('Error')"""
```

```
In [21]: """
         # Aquí levantamos el archivo generado y reducimos su tamaño si
         #es necesario
         df = pd.read_csv("propertiesConCat.csv", low_memory = False)

         #Borramos la columna "extra"
         if 'extra' in df:
             df.drop('extra', axis = 1, inplace = True)

         #Borramos la columna "Unnamed: 0"
         df.drop(df.columns.values[0], axis = 1, inplace = True)

         #Volvemos a guardar los cambios en el archivo csv
         df.to_csv("propertiesConCat.csv", index = True, header = True, sep = ',', \
             encoding = 'utf-8-sig')"""
```

4 Se abre el archivo csv concatenado

```
In [3]: #Abrimos el dataframe unificado
        df = pd.read_csv("propertiesConCat.csv", low_memory = False)
```

5 Analisis de la variacion del precio respecto del tiempo

Se espera que al agrupar los precios según la fecha en la cual fueron publicados se verá una tendencia creciente a medida que avanzamos en el transcurso de los meses. Se prevee que esto ocurrirá tanto para una análisis discreteado para Gran Buenos Aires como para Capital Federal.

6 Mostramos como varia el precio año a año de Capital Federal

```
In [4]: CF = df.loc[df.place_with_parent_names.str.contains('Capital Federal'), :]
        CF = CF.loc[:, ['date', 'price_aprox_usd']].groupby('date').agg([np.mean, np.size])\
```

```
        .reset_index()

    CF.loc[:, ['date']] = pd.to_datetime(CF['date'], errors = 'coerce')
    CF['year'] = CF['date'].dt.year
    CFYear = CF.loc[:, [('year', ''), ('price_aprox_usd', 'mean')]].groupby('year')\
        .agg([np.mean, np.size]).reset_index()

    CFYear.plot(x='year', y=('price_aprox_usd', 'mean', 'mean') , kind='line', \
                title="CapFed Prices per year")
```

```
/home/sebastian/.local/lib/python2.7/site-packages/pandas/core/base.py:331: PerformanceWarning:
  return self.obj.drop(self.exclusions, axis=1)
```

```
Out[4]: <matplotlib.axes._subplots.AxesSubplot at 0x7fd0ff8c7610>
```

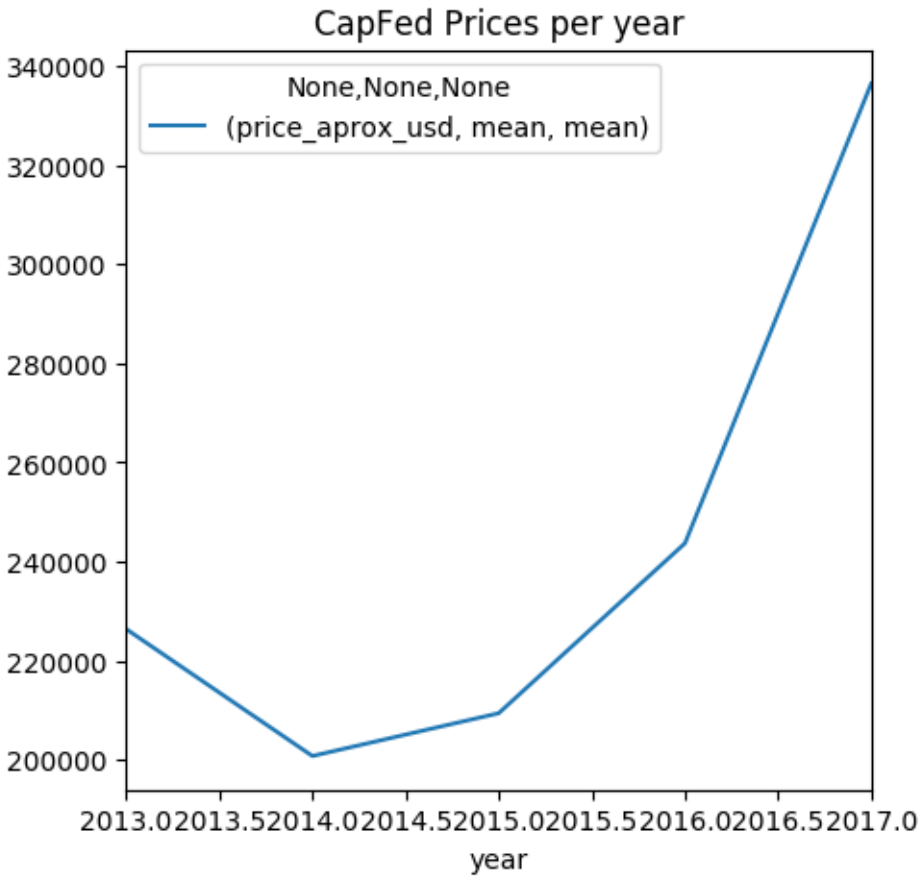

Analizando los años en Capital Federal se puede ver que los precios de las propiedades empezaron a disminuir en el 2013. Seguido de una leve recuperación recuperación en el 2015 y un crecimiento exponencial para el 2017.

7 Mostramos como varia el precio mes a mes de Capital Federal

```
In [215]: CF.plot(x='date', y=('price_aprox_usd', 'mean') , kind='line', title="CapFed Prices")
```

```
Out[215]: <matplotlib.axes._subplots.AxesSubplot at 0x7f1c92d4a310>
```

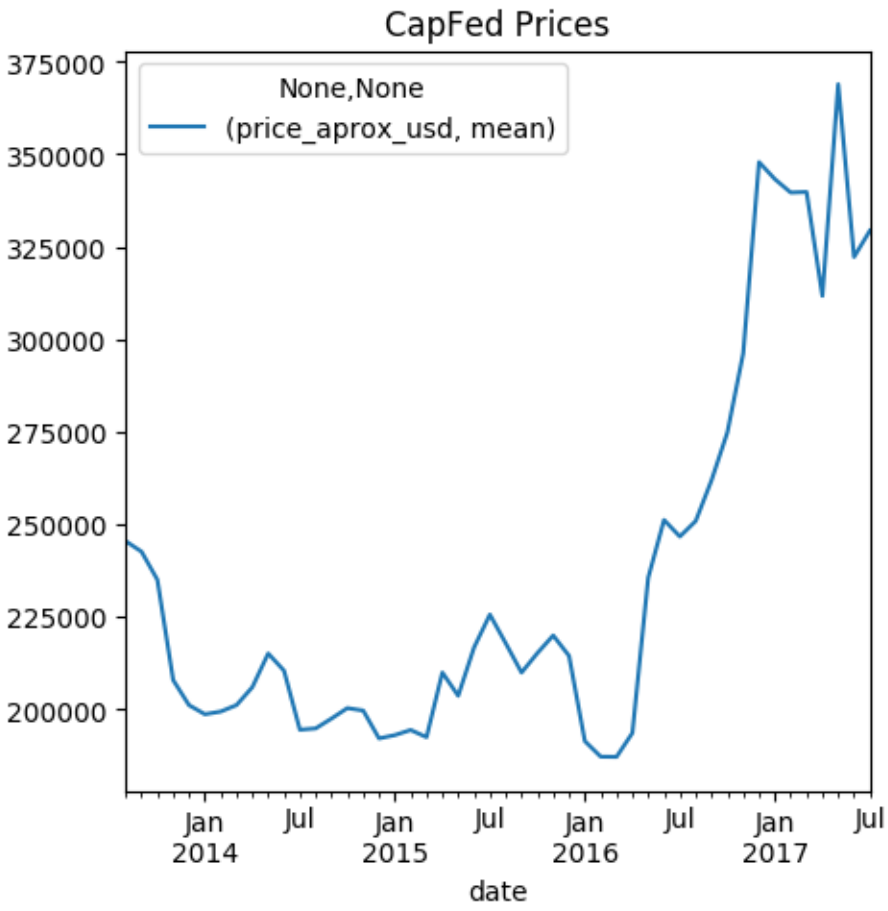

Viendo los meces se puede apreciar mejor la variación, las altas y bajas que hay en el valor promedio de una propiedad, en el cual se ve que la tendencia es creciente en especial en el primer semestre de 2017.

8 Mostramos como varia el precio año a año de Gran Buenos Aires

```
In [5]: GBA = df.loc[df.place_with_parent_names.str.contains('Bs.As. G.B.A.'), :]
        GBA = GBA.loc[:, ['price_aprox_usd', 'date']].groupby('date')\
            .agg([np.mean, np.size]).reset_index()
        GBA.loc[:, [('date', '')]] = pd.to_datetime(GBA[('date', '')], errors = 'coerce')
        GBA['year'] = GBA[('date', '')].dt.year
        GBAYear = GBA.loc[:, [('year', ''), ('price_aprox_usd', 'mean')]]\
            .groupby('year').agg([np.mean, np.size]).reset_index()
```

```
GBAYear.plot(x=('year', '', ''), y=('price_aprox_usd', 'mean', 'mean') , \
             kind='line', title="GBA Prices per year")
```

```
Out[5]: <matplotlib.axes._subplots.AxesSubplot at 0x7fd0fe721090>
```

Lo mismo pasa para Buenos Aires que experimenta una caída del promedio en 2014, pero logro recuperarse y crecer al poco tiempo.

9 Mostramos como varia el precio mes a mes de Gran Buenos Aires

```
In [77]: GBA.plot(x='date', y=('price_aprox_usd', 'mean') , kind='line', title="GBA Prices")
```

```
Out[77]: <matplotlib.axes._subplots.AxesSubplot at 0x7f100ec7f1d0>
```

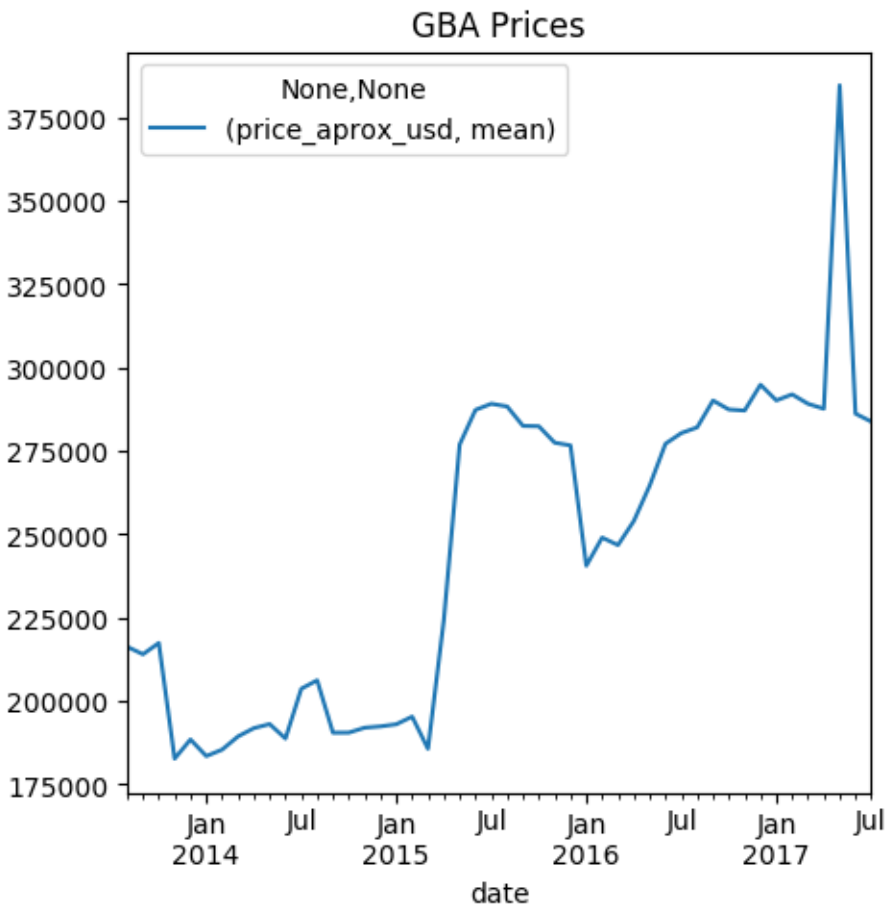

10 Variacion de precios en funcion del tipo de propiedad en Gran Buenos Aires

Se espera que el precio dependa de qué tipo de propiedades es (casa, PH, apartamento, tienda).

```
In [78]: GBA = df.loc[df.place_with_parent_names.str.contains('Bs.As. G.B.A.'), :]
         GBA = GBA.loc[:, ['property_type', 'price_aprox_usd']].groupby('property_type')\
             .agg([np.mean, np.size]).reset_index()
         GBA.plot(x='property_type', y=('price_aprox_usd', 'mean') , kind='bar', \
                  title="GBA Prices by property type")

Out[78]: <matplotlib.axes._subplots.AxesSubplot at 0x7f100eb52250>
```

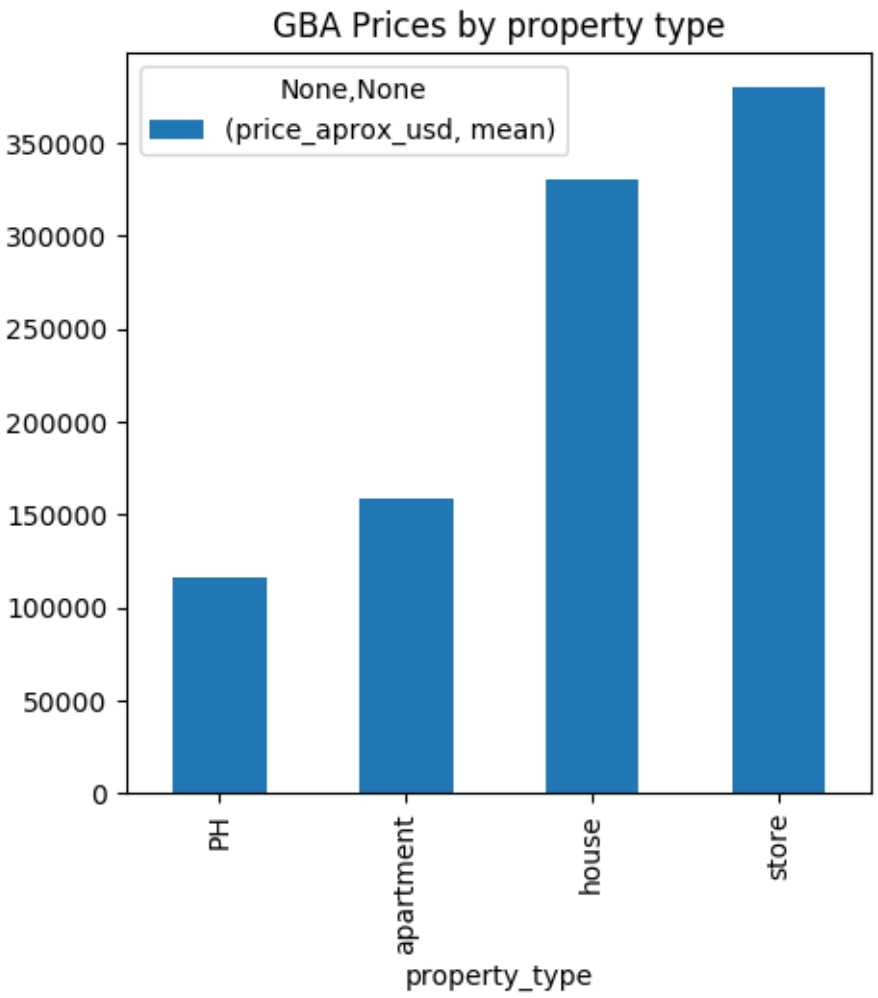

11 Variacion de precios en funcion del tipo de propiedad en Capital Federal

```
In [79]: CF = df.loc[df.place_with_parent_names.str.contains('Capital Federal'), :]
         CF = CF.loc[:, ['property_type', 'price_aprox_usd']].groupby('property_type')\
             .agg([np.mean, np.size]).reset_index()
         CF.plot(x='property_type', y=('price_aprox_usd', 'mean') , kind='bar', \
                 title="top20 CapFed Prices by property type")
```

```
Out[79]: <matplotlib.axes._subplots.AxesSubplot at 0x7f100eb33d10>
```

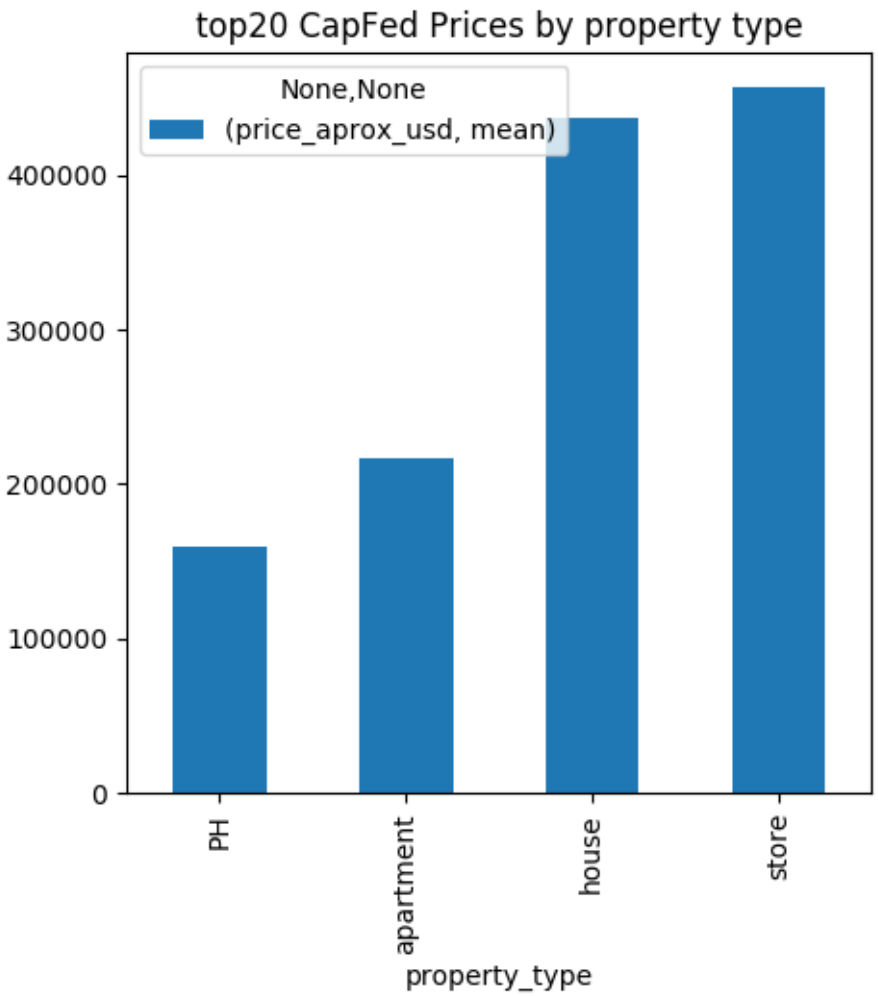

Para poder analizar si el precio dependía del tipo de propiedad que es, el data frame se agrupo por el tipo de propiedad que es en un grafico de barras , tanto para Capital Federal como para Buenos Aires. Al analizar el grafico se puede ver que las propiedades que más valen son las tiendas seguido de las casas. Y tanto PH como apartamento valen la mitad o menos que las otras.

12 Análisis de datos en función de la cercania a cierto lugar o institucion

Esta funcion recibe dos coordenadas de latitud, longitud y devuelve la distancia en metros que las separa

```
In [8]: def ManhattanDistance(lat1, lon1, lat2, lon2):
            # pasamos la diferencia a metros (90º son 10000 Km)
            dlat = abs(lat1-lat2) * (10000/90)
            # pasamos la diferencia a metros (360º son 40000 Km)
            dlon = abs(lon1-lon2) * (40000/360)
```

```
        distKM = ( (dlat ** 2) + (dlon ** 2) ) ** (0.5)
        return float(distKM * 1000)
```

Esta funcion recibe el dataFrame de las propiedades y una dataFrame extra que puede representar universidades, paradas de colectivo, paradas de subte u hospitales y devuelve el dataFrame de las propiedades con una columna adicional la cual muestra la distancia minima a cierto ligar de los antes mencionados con su precio en dolares promedio. De esta manera, se puede mostrar una representación grafica del precio promedio en funcion de esta distancia minima pudiendo comprobar si hay relevancia la cercania a estos lugares en el precio

```
In [9]: def distanceAnalysis(df, extraDf, lat, lon, groupbyPlaceName=False):
            extraDf.loc[:, [lon]] = extraDf.loc[:, [lon]].apply(lambda x: float(x), axis = 1)
            extraDf.loc[:, [lat]] = extraDf.loc[:, [lat]].apply(lambda x: float(x), axis = 1)
            extraDf = extraDf[~np.isnan(extraDf[lon]) | ~np.isnan(extraDf[lat])]

            df = df[~np.isnan(df['lon']) | ~np.isnan(df['lat'])]
            df = df[~np.isnan(df['price_aprox_usd'])]
            if groupbyPlaceName:
                df = df.loc[:, ['lon', 'lat', 'price_aprox_usd', 'place_name']]\
                .groupby('place_name').agg([np.mean, np.size]).reset_index()
                df = df[~np.isnan(df[('lon', 'mean')]) | ~np.isnan(df[('lat', 'mean')])]

                aux = pd.DataFrame()
                aux['lon'] = df[('lon', 'mean')]
                aux['lat'] = df[('lat', 'mean')]
                aux['price_aprox_usd'] = df[('price_aprox_usd', 'mean')]
                aux['place_name'] = df['place_name']
                df = aux

            latDf = df['lat'].tolist()
            lonDf = df['lon'].tolist()
            x = extraDf[lon].tolist()
            y = extraDf[lat].tolist()

            distances = []
            minor = 0;

            for i in range(0, len(latDf)):
                minor = ManhattanDistance(y[0], x[0], latDf[i], lonDf[i])
                for j in range(1, len(x)):
                    dist = ManhattanDistance(y[j], x[j], latDf[i], lonDf[i])
                    if (dist < minor):
                        minor = dist
                distances.append(minor)

            df['distances'] = pd.Series(distances)
            df = df.loc[:, ['distances', 'price_aprox_usd']].groupby('distances')\
                .agg([np.mean, np.size]).reset_index()
```

```
    df = df.sort_values(by=('distances', ''), ascending=True)
    df = df[~np.isnan(df[('price_aprox_usd', 'mean')])]
    df = df[df[('price_aprox_usd', 'mean')] > 0]
    df = df[df[('price_aprox_usd', 'size')] > 200]
    return df
```

13 Grafico de la variacion del precio en dolares en funcion de la cercania a una parada de subte

Se espera que la relación del promedio de los precios en dólares de cada propiedad en función de la cercanía a cierta estación de subte influirá en la suba del mismo, es decir, que al estar mas cerca de la parada de un subte, mas caro será la propiedad.

```
In [204]: subways = pd.read_csv('./extra/estaciones-de-subte.csv', low_memory=False)
          CF = df.loc[df.place_with_parent_names.str.contains('Capital Federal'), :]
          CF = CF[CF['place_name'] != "Capital Federal"]
          CF = distanceAnalysis(df, subways, 'Y', 'X', False)
```

```
In [205]: CFPlot.plot(x=('distances', ''), y=('price_aprox_usd', 'mean') , kind='line', \
                      title="Price depending on distance in meters from subway")
```

```
Out[205]: <matplotlib.axes._subplots.AxesSubplot at 0x7f1c9343f190>
```

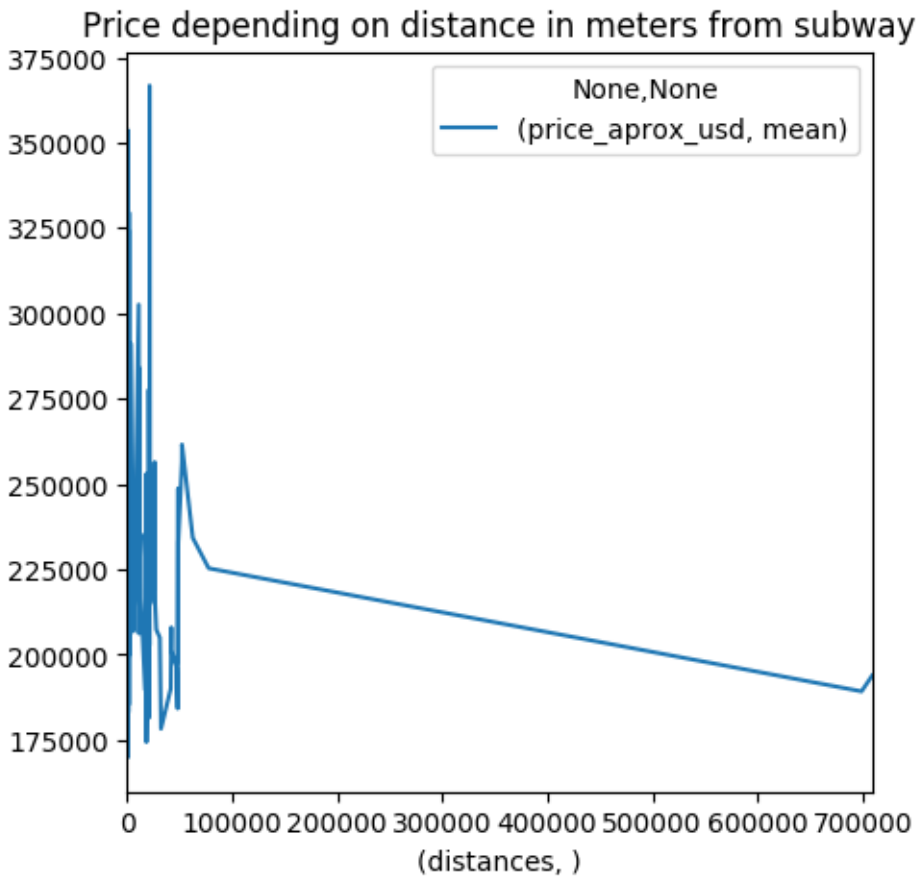

Como se puede ver en el grafico para distancias pequeñas se puede ver como varia demasiado el precio, y que a partir de los 100000 m aproximadamente el precio empieza a bajar linealmente.

14 Grafico de la variacion del precio en dolares en funcion de la cercania a un hospital

Se espera que la relación del promedio de los precios en dólares de cada propiedad en función de la cercanía a los hospitales influirá en la suba del mismo, es decir, que al estar mas cerca de un hospital, mas caro será la propiedad.

```
In [10]: hospitals = pd.read_csv("./extra/hospitales.csv", low_memory=False, \
                                 sep=';', error_bad_lines=False)
         BsAs = distanceAnalysis(df, hospitals, 'LAT', 'LNG', False)

In [14]: # Filtro Las distancias lejanas porque si no la escala
         # no se ve favorecida para graficarlos puntos calculados
         BsAsPlot = BsAs[BsAs[('distances', '')] < 10**7]
         BsAsPlot = BsAsPlot[BsAsPlot[('price_aprox_usd', 'mean')] < 10**7]
         BsAsPlot.plot(x=('distances', ''), y=('price_aprox_usd', 'mean') , kind='line', \
                       title="price depending on distance from hospitals")

Out[14]: <matplotlib.axes._subplots.AxesSubplot at 0x7fd0fe652250>
```

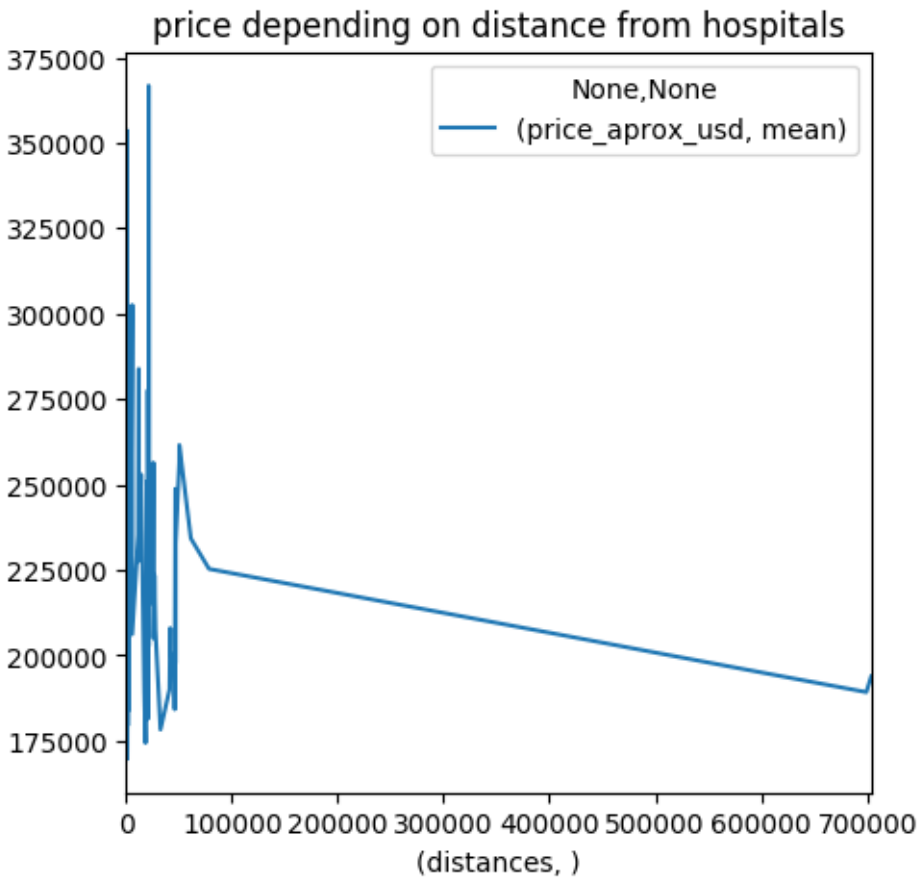

La relación de los precios de las propiedades con la distancia a los hospitales, como se esperaba para distancias pequeñas tiende a ser mayor a pesar de tener altas y bajas.

15 Grafico de la variacion del precio en dolares en funcion de la cercania a una parada de subte

la primer funcion recibe un string y cambia la coma por un punto. Esto se debe a que el dataFrame delas paradasde colectivo tiene las coordenadas de latitud y longitud en formato string y ademas el nuemro tiene separada la parte decimal por una coma, por lo cual no se lo puede convertir a float. Es necesario cambiar esa coma por un punto.

La segunda funcion cambia la lista de string que tiene numeros decimales, los cuales separan la parte entera de la decimalpor una coma, por una lista de numeros de tipo float, logrando antes cambiar esa coma por un punto para poder hacer la conversion

Se espera que la relación del promedio de los precios en dólares de cada propiedad en función de la cercanía a la parada de los colectivos influirá en la suba del mismo, es decir, que al estar mas cerca de la parada de un colectivo, mas caro será la propiedad.

```
In [198]: def changeStringCommaForPoint(string):
              point = "."
```

```
        split = string.split(',')
        return point.join(split)
    def changeStringListCommaForPoint(stringList):
        aux = []
        for string in stringList:
            aux.append(changeStringCommaForPoint(string))
        return aux
```

In [199]:
```
busStops = pd.read_csv("./extra/paradas-de-colectivo.csv", \
                       low_memory=False, sep=';', error_bad_lines=False)
busStops['X'] = pd.Series(changeStringListCommaForPoint(busStops['X'].tolist()))
busStops['Y'] = pd.Series(changeStringListCommaForPoint(busStops['Y'].tolist()))
busStops.loc[:, 'X'] = busStops.loc[:, ['X']].apply(lambda x: float(x), axis = 1)
busStops.loc[:, 'Y'] = busStops.loc[:, ['Y']].apply(lambda x: float(x), axis = 1)

CF = df.loc[df.place_with_parent_names.str.contains('Capital Federal'), :]
CF = distanceAnalysis(CF, busStops, 'Y', 'X', True)
```

In [200]:
```
CFPlot.plot(x=('distances', ''), y=('price_aprox_usd', 'mean') , kind='line', \
        title="price depending on distance in kilometers from Bus stops")
```

Out[200]:
```
<matplotlib.axes._subplots.AxesSubplot at 0x7f1c98885190>
```

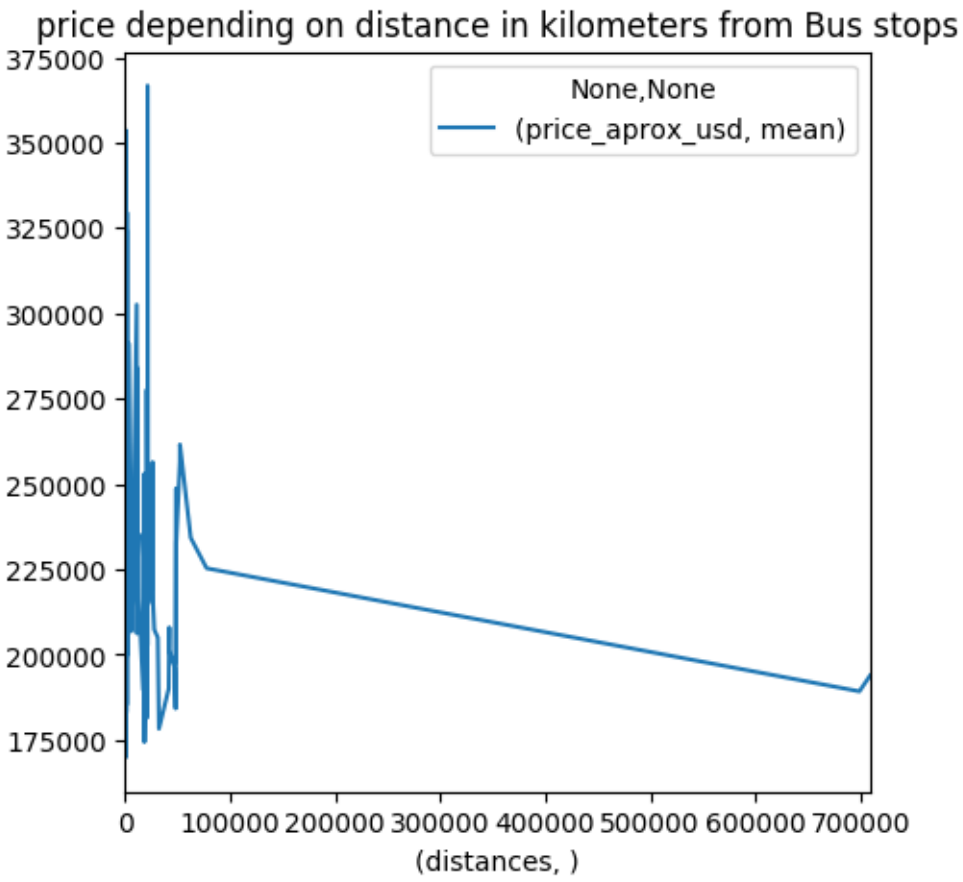

Para la variación de precios promedio respecto de las distancia a las paradas de colectivos es muy similar a la que tiene con la distancia a hospitales y estaciones de subte.

16 Grafico de la variacion del precio en dolares en funcion de la cercania a las universidades

Para este analisis se espera ver que si una propiedad es cercana a ana Univesidad su precio tiende a crecer.

```
In [201]: universities = pd.read_csv("./extra/universidades.csv", low_memory=False, \
                                     sep=';', error_bad_lines=False)
          universities.loc[:, 'LNG'] = universities.loc[:, ['LNG']]\
              .apply(lambda x: float(x), axis = 1)
          universities.loc[:, 'LAT'] = universities.loc[:, ['LAT']]\
              .apply(lambda x: float(x), axis = 1)
          universities = universities[~np.isnan(universities['LNG']) | \
                                      ~np.isnan(universities['LAT'])]
          BsAs = distanceAnalysis(df, universities, 'LAT', 'LNG', True)

In [203]: #BSASPlot = BSAS[BSAS[('distances', '')] < 200000]
          BSASPlot.plot(x=('distances', ''), y=('price_aprox_usd', 'mean') , kind='line', \
                        title="price depending on distance in kilometers from Universities")

Out[203]: <matplotlib.axes._subplots.AxesSubplot at 0x7f1c93364bd0>
```

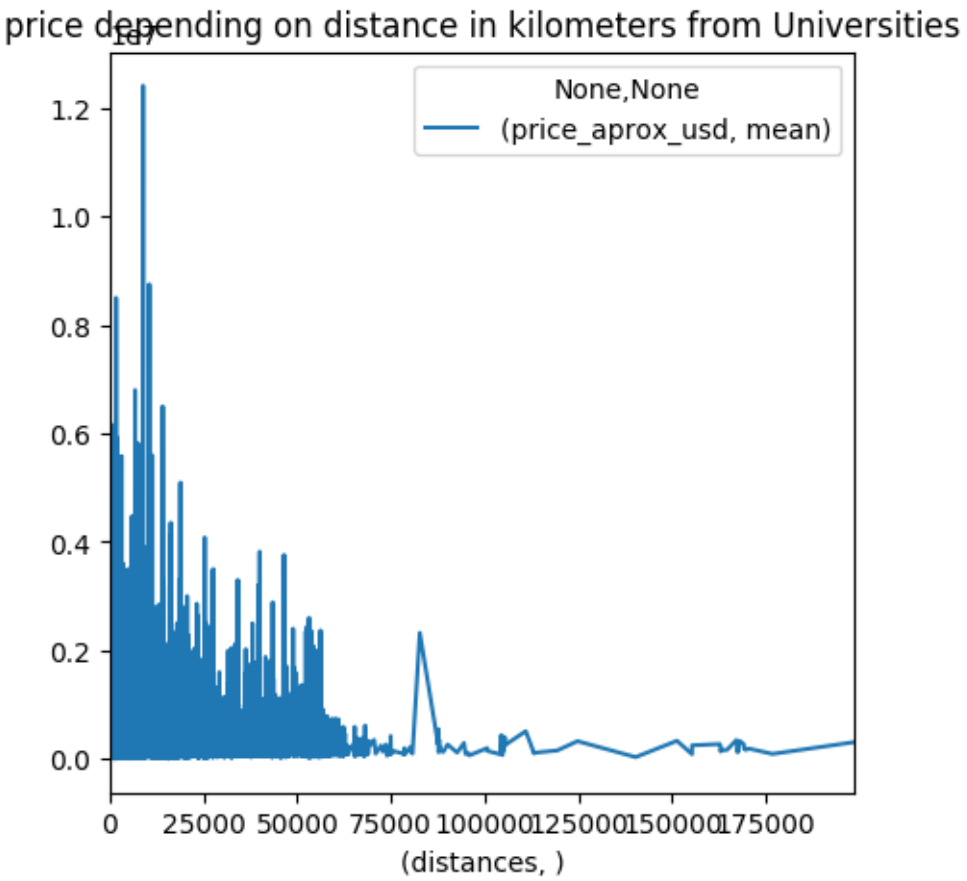

Viendo el grafico las las propiedades con distancias enores a 25000 tienen mayyores precios. Pasando esa distancia las propiedades tienden a a tener menores precios.

16.1 Variacion de precio de las casas en funcion de la cantidad de ambientes

Se espera que el precio promedio de las propiedades en función de la cantidad de ambientes de las casas será mayor, es decir, que a medida que aumentan las cantidad de ambientes, aumenta el precio promedio.

```
In [16]: houses = df[df['property_type'] == 'house']
         houses = houses[~np.isnan(houses['rooms'])]
         houses = houses[houses['rooms'] != 0]
         houses = houses.loc[:, ['rooms', 'price_aprox_usd']].groupby('rooms')\
             .agg([np.mean, np.size]).reset_index()
         houses = houses[houses[('price_aprox_usd', 'size')] >= 10]
         houses.plot(x=('rooms', ''), y=('price_aprox_usd', 'mean') , kind='bar', \
                         title="houses prices depending on rooms' quantity")

Out[16]: <matplotlib.axes._subplots.AxesSubplot at 0x7f7128d8ce10>
```

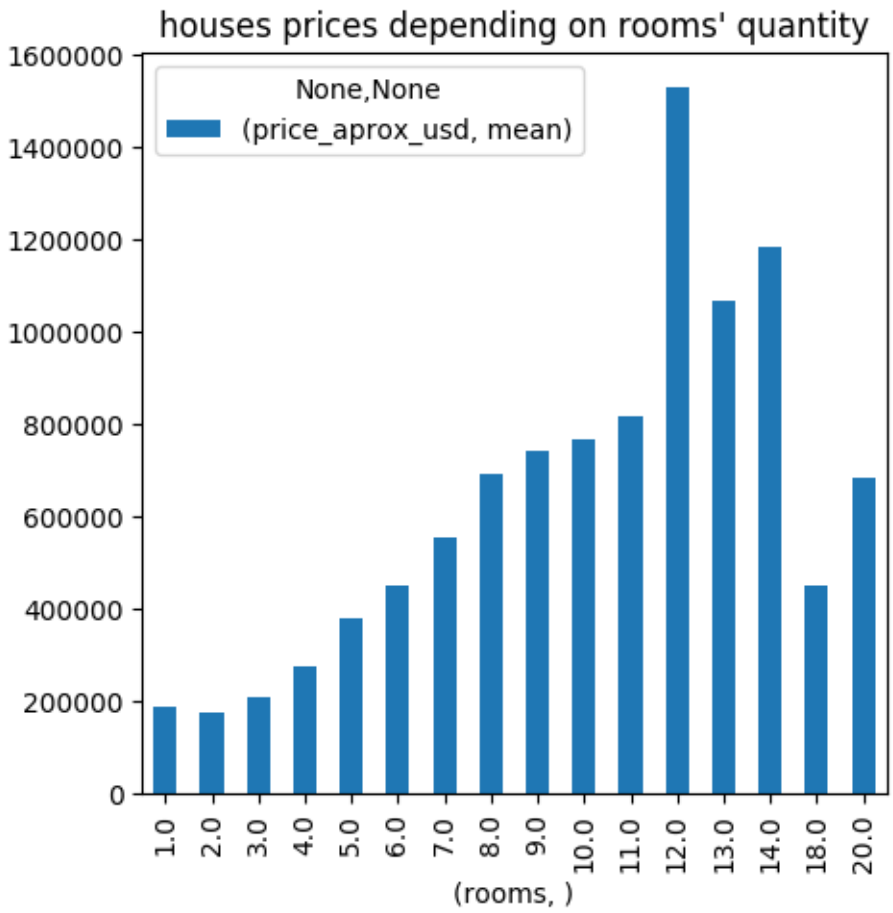

Lo que se puede ver es que tiene una tendencia creciente hasta llegar a 12 donde encuentra su máximo y luego empieza a disminuir el promedio.

17 Grafico de densidades de los barrios de capital federal en función de el precio promedio en dolares

Estas tres funciones conviertes el dataFrame a geoDataFrame.

La primer funcion reemplaza las columnas lat y lon por una columna necesaria para el dataFrame la cual se llama geometry. Esta contiene la latitud y longitud en forma de objeto Point que representa un punto o coordenada del mapa.

La segunda función recibe un dataFrame que representa un mapa, que puede ser la división por barrio de la capital Federal o la division por distritos escolares o por comuna, etc, y reemplaza la columna WKT que en general contiene una lista de poligonos, que representa un area, la columna geometry.

La tercer funcion convierte una lista de string de poligonos a el objetos de lista de objetos poligonos. Esto es necesario ya que la mayoria de los DataFrame que prepresentan algun tipo de mapa, vienen con este tipo de inconvenientes.

```
In [7]: def convertToGeoData(df):
            geometry = [Point(xy) for xy in zip(df.lon, df.lat)]
            df = df.drop(['lat', 'lon'], axis = 1)
            crs = {'init': 'epsg:4326'}
            geoDf = gpd.GeoDataFrame(df, crs = crs, geometry = geometry)
            return geoDf
        #-------------------------------------------------------------------
        def convertToGeoDataFrame(df):
            geometry = [Polygon(x) for x in df['WKT'].tolist()]
            crs = {'init': 'epsg:4326'}
            geoDf = gpd.GeoDataFrame(df, crs = crs, geometry = geometry)
            return geoDf
        #-------------------------------------------------------------------
        def convertStringToPolygon(listOfPolygons):
            import re
            finalList = []
            pat = re.compile(r'''(-*\d+\.\d+ -*\d+\.\d+);*''')
            for s in listOfPolygons:
                matches = pat.findall(s)
                if matches:
                    finalList.append([tuple(map(float, m.split())) for m in matches])
            return finalList
```

La primer funcion realiza el filtrado y agrupamiento por barrio de capital federal del DataFrame de las propiedades. Se filtraron las proiedades con longitud y latitud con valor de Nan, y tambien aquellas longitudes y latitudes cuyos valores se encunetren en el rango que se ve en el código. Esto se hizo ya que a pesar de agrupar por barrio de la Capital Federal, hay propiedades que se encontraban por fuera de este rango que es el la Ciudad de buenos Aires pertenece. Es decir, que hay errores graves en el archivo CSV donde hay propiedades donde dicen ser de capital Federal pero su longitud y/o latitud no pertenecen al conjunto de las mismas que estan contenidas en Capital Federal.

La segunda funcion recibe dos GeoDataFrames, uno que contiene en su columna de goemetry una serie de objetos Points, que son coordenadas longitud, latitud en el mapa, y el otro contiene una serie de objetos Polygon. Se itera por cada propiedad, que seria el primer geoDataFrame, y por cada Polygono se pregunta si elpunto pertenece. De esta manera se reemplaza la columna geometry del primer geoDataFrame de propiedades con una serie de Polygons de tal manera que queden las propiedades con su respetiva area de polygono que puede representar un barrio, una comuna o un distrito escolar.

```
In [8]: def densityMapByPlaceName(df, place):
            densityMap = df
            if place == 'Capital Federal' or place == 'Bs.As. G.B.A.':
                densityMap = densityMap.loc[densityMap.place_with_parent_names.str\
                                            .contains(place), :]

            densityMap = densityMap[~np.isnan(densityMap['lat']) | \
                                    ~np.isnan(densityMap['lon'])]
```

```
    densityMap = densityMap[(densityMap['lon'] <= -58.0) & \
                            (densityMap['lon'] >= -58.55)]

    densityMap = densityMap[(densityMap['lat'] <= -34.530) & \
                            (densityMap['lat'] >= -34.73)]

    densityMap = densityMap.loc[:, ['place_name', 'price_aprox_usd', \
                                    'lat', 'lon']].groupby('place_name')\

    .agg([np.mean, np.size]).reset_index()

    aux = pd.DataFrame()
    aux['place_name'] = densityMap[('place_name', '')]
    aux['price_aprox_usd'] = densityMap[('price_aprox_usd', 'mean')]
    aux['lon'] = densityMap[('lon', 'mean')]
    aux['lat'] = densityMap[('lat', 'mean')]
    densityMap = aux

    densityMap = densityMap[~np.isnan(densityMap['price_aprox_usd'])]
    return densityMap
#-------------------------------------------------------------------------------------------
def belongToPolygon(geoDf, buenosAiresMap):
    polygons = []
    for point in geoDf['geometry'].tolist():
        for polygon in buenosAiresMap['geometry'].tolist():
            if polygon.contains(point):
                polygons.append(polygon)
                continue
    geoDf['geometry'] = gpd.GeoSeries(polygons)
    return geoDf
```

Se espera que al agrupar los precios promedio de las propiedades por cada barrio de la ciudad de buenos aires, se verán distribuidos de tal manera que la parte norte de esta localidad será el lugar donde se concentra la zona mas cara de la misma.

```
In [9]: densityMapDf = densityMapByPlaceName(df, 'Capital Federal')
        geoDf = convertToGeoData(densityMapDf)

        buenosAires = pd.read_csv('barrios.csv', low_memory = False)
        buenosAires['WKT'] = pd.Series(convertStringToPolygon(buenosAires['WKT'].tolist()))
        buenosAiresMap = convertToGeoDataFrame(buenosAires)

        geoDf = belongToPolygon(geoDf, buenosAiresMap)
        geoDf.plot(legend=True, column = 'price_aprox_usd', cmap='OrRd', \
                   scheme="Quantiles", figsize=(10,10))
        plt.title('Variacion del precio en Ciudad de Buenos Aires', fontsize = 20)

Out[9]: <matplotlib.text.Text at 0x7f1ca3b8b3d0>
```

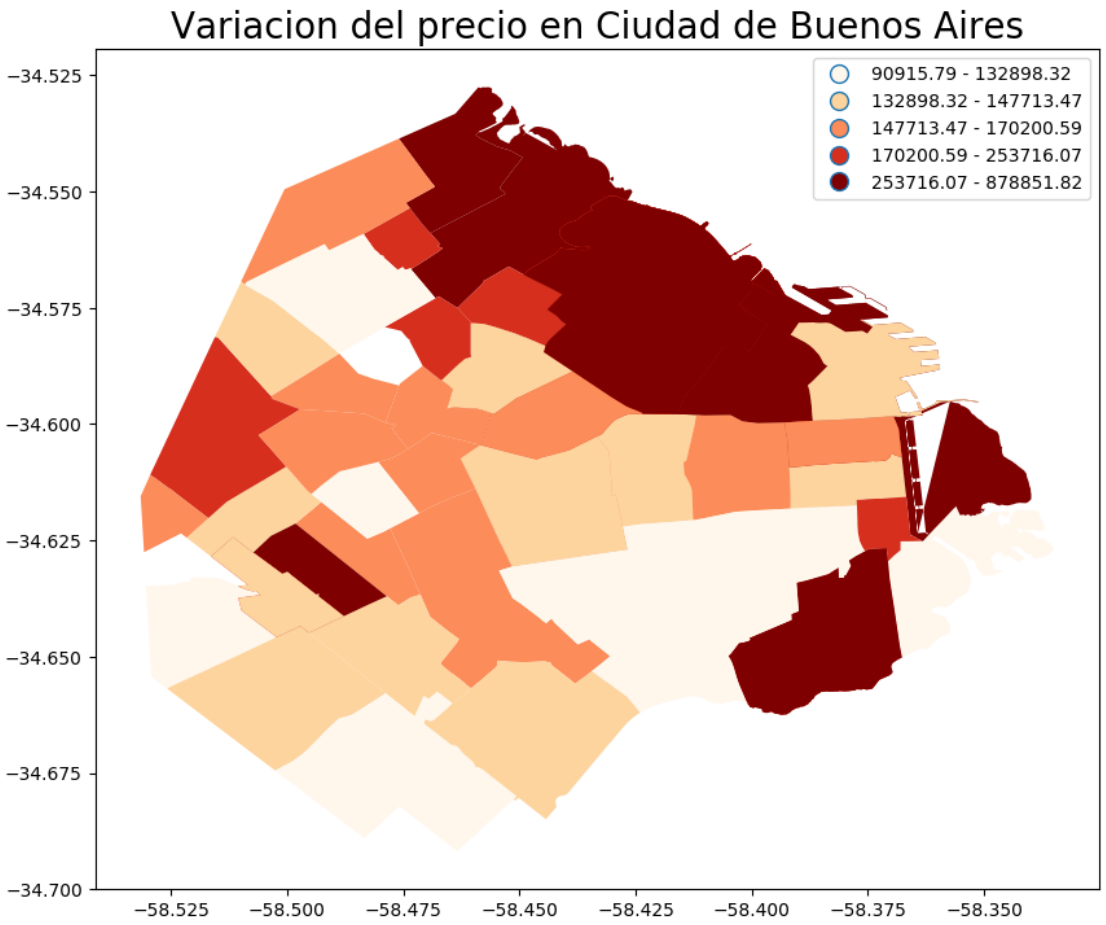

Como se puede ver en el mapa en los distritos en el norte de Capital Federal es donde el promedio de los precios es el mayor. Que coincide con la zona de Palermo.

18 Análisis de la variación de precios en función de la cercania a distritos escolares

En este análisis se tuvo en cuenta como se dstrinuyen los distritos escolares en el mapa de buenos aires. De esta manera se nota que la división en el territorio que se ve en el mapa es distinta a la división real del mapa de los barrios del mismo. Se mezclaron los archivos de geoDataFrame de los distritos escolares y de las propiedades de tal manera se agrego a esta ultima el poligono que representa la división de distritos.

```
In [32]: schoolDistricts = pd.read_csv("./extra/distritos-escolares.csv", \
                                        low_memory=False, sep=',', error_bad_lines=False)
         schoolDistricts['WKT'] = pd.Series(convertStringToPolygon(schoolDistricts['WKT']\
                                                                   .tolist()))
         schoolDistrictsMap = convertToGeoDataFrame(schoolDistricts)
```

```
NeiighbourgoodPrices = densityMapByPlaceName(df, 'Capital Federal')
geoDf = convertToGeoData(NeiighbourgoodPrices)
geoDf = belongToPolygon(geoDf, schoolDistricts)
geoDf.plot(legend=True, column = 'price_aprox_usd', cmap='OrRd', \
           scheme="Quantiles", figsize=(10,10))
plt.title('Densidad de precios en CABA en funcion de la cercania a  \
    los distritos escolares', fontsize = 20)
```

```
Out[32]: <matplotlib.text.Text at 0x7f1c9a4f75d0>
```

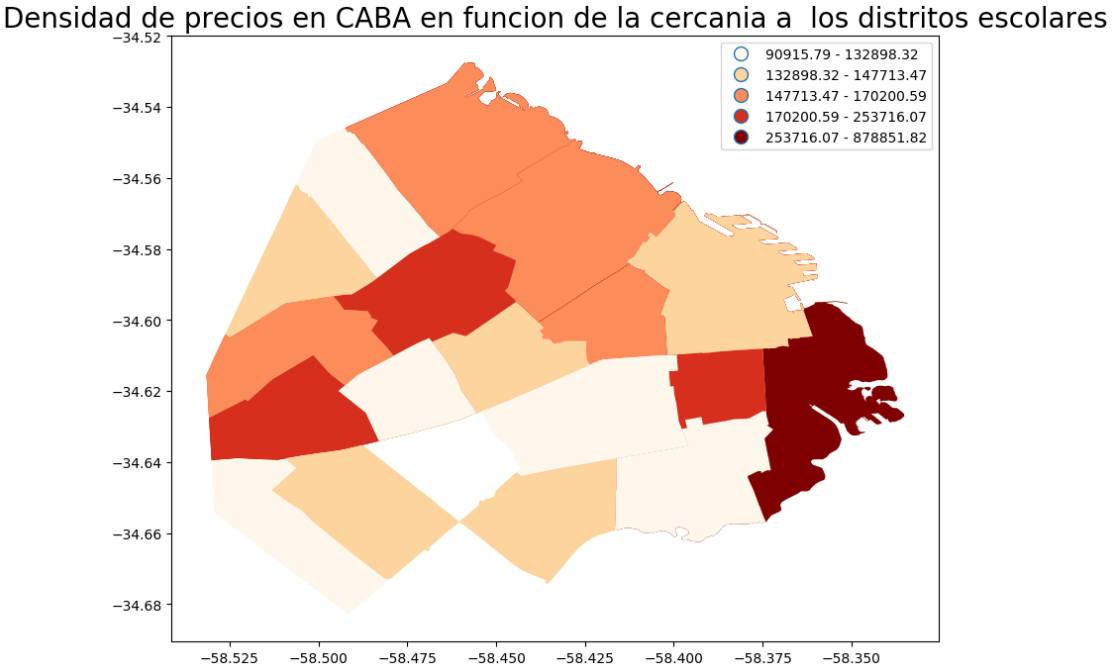

Cuando tomamos en cuenta los districtos escolares se puede ver que los mayores precios se encuentran en el este y centro de capital Federal. La zona de mayor precio en promedio corresponde a Puerto Madero.